跨資產 ETF 動能 × 波動狀態：一次完整的 ML4T 研究循環

ML for Algorithmic Trading · Midterm Proposal ｜ 作者： ｜ 2026–11–08 ｜ setup_version v1 ｜ 規格雜湊 `7e75995d042147ae`（holdout 執行前凍結）

摘要　以 100 檔跨資產 ETF（2006–2025，Yahoo Finance）建立月頻、只做多的排名策略：機制是「資金移動緩慢、投資人反應不足」造成 6–12 個月相對強弱延續，並假設高波動期間（動能崩潰）會讓這個效果失效。我依 ML4T 流程完成一圈：先寫好 `setup.yaml` 與驗證協定並封存 2024–2025 holdout → 時間點正確的資料管線 → 22 個候選特徵、五道關卡篩選（0 PROCEED / 9 REVISE / 8 STOP）→ 規則 / Ridge / LightGBM 階梯 → 含成本、配置與風控的回測 → holdout 前的洩漏檢查 → **只跑一次** holdout。部署模型（LightGBM）在驗證期日 IC 0.078 [0.042, 0.113]、淨 Sharpe 0.63 [−0.02, 1.29]；holdout 日 IC 0.064 [−0.014, 0.142]、淨 Sharpe 1.08 [−0.31, 2.47]，**預先登錄的確認檢定通過，但兩個信賴區間都含 0**，且在 holdout 中 ML 的優勢沒有轉成投組優勢（Sharpe 低於 12–1 規則的 1.35 與 60/40 的 1.39）。Deflated Sharpe（N = 93 次試驗）只有 0.28（驗證）與 0.17（holdout）。結論：依 Ch. 20 屬於「**never resolved**」型態（兩段淨 Sharpe 區間皆含 0）；訊號方向維持，但價值在投組轉換關卡流失。另外，稽核後以重新下載的資料（調整因子僅差約 10^{-6}）重跑開發期，Optuna 會選出不同的超參數，部署規則也改選 12–1 規則，顯示 ML 相對優勢並不穩健。證據不足以投入資金；下一步是降低轉換損失（換手），而不是再調參數。

1. 假說與優勢來源（Ch. 1, 6）

機制（兩句話）　資金移動緩慢與投資人反應不足，使跨資產 ETF 過去 6–12 個月的相對表現在下一個月延續；配置者依日曆再平衡、或錨定舊價格的投資人，是交易的對手方。這種延續在波動剛飆升之後最弱，因為崩跌過的輸家會劇烈反彈（momentum crash），所以波動狀態應該能「開關」這個訊號。

優勢來源（Table 6.1）　資金流可預測（flow predictability）為主，風險補償（承擔崩潰風險）為輔。採「機制優先」入口，研究範圍因此被限制在價格動能家族與少數狀態變數。

證偽條件（事先寫入 `setup.yaml`）　① 規則基準與部署模型的驗證期 IC 之 Newey–West 95% CI 含 0 → 停止；② 損益兩平成本 < 2 倍假設成本 → 不可交易；③ holdout 淨 Sharpe < 0 或平均 IC ≤ 0 → 未確認；④ 高波動三分位的動能 IC 不低於平靜三分位 → 波動開關機制被否定。

> **What could break this**　ETF 動能的對手方是誰並不像個股那樣清楚；若跨資產動能其實只是「股債輪動 + 美股 beta」，那它是風險暴露而非優勢（第 6 節滾動 beta ≈ 0.90 顯示這個疑慮是真的）。另外，2010 年代後 CTA 與趨勢跟隨 ETF 規模擴大，可能讓延續效果被套利掉。

2. 交易設定 v1 與驗證協定（Ch. 6）

交易設定以 YAML 寫成並在任何回測前 commit（git 第一個 commit `73fd93f`），以下為摘要；調整參數不換版本，改變機制（例如多空、加入融資成本）即升為 v2。

欄位	設定
股票池與資格	100 檔 ETF（9 類）；在 t 日收盤時：歷史 ≥ 273 交易日，且過去 63 日「未調整收盤價 × 未調整成交量」中位數 ≥ 1,000 萬美元
決策時程	月底最後一個交易日收盤產生分數 → 下一交易日**開盤**成交（延遲 1 個交易日），持有至下次再平衡開盤
可用資訊	t 日收盤前的調整後 / 未調整 OHLCV；v1 不使用任何非價格資料；最長回看 252 日
分數→交易	依分數取前 10 名、等權 10%、只做多、滿倉；無法成交狀態：成交日無有效開盤價則不交易、保留原權重；可用標的不足 10 檔時差額持現金
限制	槓桿 1.0、不放空、單檔上限 10%，在模擬迴圈內每次再平衡檢查
成本類別	每股 $0.0035 手續費 + 分級半價差（大型 ETF 0.5¢、XL 類股 1¢、其他 2¢），以**未調整開盤價**換算 bps；壓力測試價差 ×3

驗證協定（六項承諾）　擴張式訓練窗（自 2007–01–01）；步長 1 年；每年初重訓；標籤期間 21 交易日；label buffer（purge）22 交易日（標籤讀到 open[t+22]）；embargo 0（訓練永遠在驗證之前）；最長特徵回看 252 日。資料切分如下，實際日期記錄於附錄 A2：

用途	期間	說明
特徵篩選（discovery）	2008–01–01 ～ 2014–11–28	末端已 purge，標籤不跨入 2015
超參數調整（固定切分）	訓練 ≤ 2013–11–27；驗證 2014–01–02 ～ 2014–11–28	Ridge α 與 LightGBM 只在此調一次後凍結
Walk–forward 驗證	2015 ～ 2023，共 9 個年度 fold	每 fold 重訓，凍結超參數
Holdout（封存）	**2024–01–01 ～ 2025–12–31**	2026–11–08 封存；程式層級閘門 `load_panel_with_holdout` 需凍結規格才能開啟，並記錄每次存取

搜尋記帳　研究帳本 `run_log.csv` 在第一次回測前就已 commit（空表頭），採 Strategy → Trial family → Trial → Run 四層；每列記錄 git commit、資料快照雜湊、設定、評估區間、指標與決策。至 holdout 為止共 **93 個試驗**（特徵 21＝17 訊號＋4 狀態、Ridge α 10、Optuna 50、模型 4、策略 / 配置 / 覆蓋 8；帳本中的去重與部署決策紀錄列不計），這個數字直接用於第 7 節的 Deflated Sharpe。**預先登錄的確認檢定**：部署階、等權前 10、假設成本、無覆蓋；holdout 平均日 IC > 0 **且** 淨 Sharpe > 0 即通過，並附 95% CI 與 DSR。

> **What could break this**　固定切分調參只用 2014 一年（約 230 天）選超參數，選到的是那一年的雜訊的風險很高；Ridge α 選在網格邊界（10^5），代表最佳正則化可能更強。部署規則「顯著勝過最佳較簡單階」的邊際很薄（見第 5 節），而且第一次（有 bug 的）執行與修正後結果不同，這屬於 forking path，已完整揭露於附錄 A3。

3. 資料：來源、時間點正確性與品質報告（Ch. 2–5）

來源（路線 B，自行下載）　Yahoo Finance via `yfinance` 1.8.0，下載時間 2026-11-08 15:19 UTC，`auto_adjust=False` 同時取得收盤價與調整後收盤價。共 470,662 列、100 檔，資料快照 SHA-256 前 12 碼 `e85bda8973a2`；用 `uv run python scripts/download_data.py` 可重新下載同一份資料（Yahoo 調整因子每次下載有約 10^{-6} 的浮點差異，雜湊會不同；本報告數字以快照 `e85bda8973a2` 為準，見第 5 節與附錄 A4）（Parquet 長表 `data/raw/etf_panel.parquet`，另存除權息 / 分割事件表與 metadata）。與課本 ETF 快照獨立比對：99 檔共同標的、4,529 個交易日，日報酬差超過 10bp 的比例為 0，中位差 0.0017bp。

時間戳記與調整　日期為 NYSE 交易日，開 / 收盤為官方 09:30 / 16:00 ET。我發現 Yahoo 的 `Close` **已經做過分割調整**（SMH 2023-05-05 一拆二當天「原始」報酬是 +2.11%），若直接拿來算每股手續費，分割前的成本會被高估或低估。因此以「分割後價格 × 之後所有分割比例」重建**實際成交價**：修正後 SMH 在除權日的未調整報酬為 −48.9%、調整後 +2.1%，美元成交量不變（已驗證）。報酬一律用調整後價格；所有以美元或股數計價的量（資格門檻、Amihud、成本）一律用重建的未調整價格。

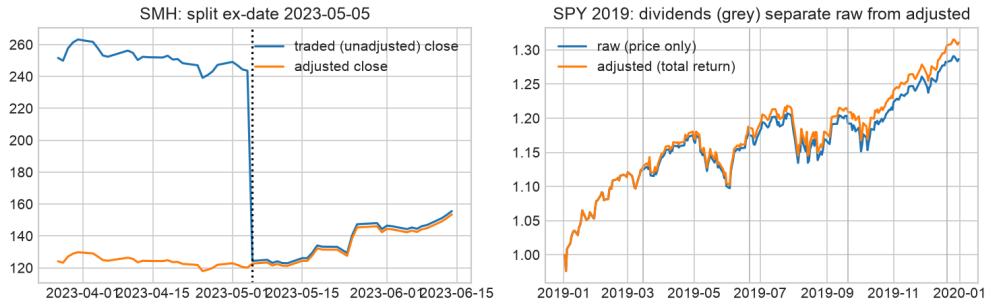


圖 3.1　Q：價格調整處理正確嗎？左：SMH 分割日未調整（實際成交）vs 調整後；右：SPY 2019 除息日（灰線）使未調整與總報酬序列分離。

時間點正確性檢查（三個層次）

Level	Check	Result
Values	Prices only; feature at t uses closes <= t (truncation test in 03)	PASS
Values	Non-price data (fundamentals, macro, text)	N/A (none used in v1)
Values	Adjusted prices are back-adjusted with *future* dividends; returns are invariant but levels are not -> levels never used in dollars	PASS (dollar quantities use raw prices)
Universe	Eligibility computed from history length and trailing 63d median $ADV at t	PASS
Universe	Leavers included (closed/merged ETFs)	FAIL – list chosen in 2025; 0 leavers in sample (survivorship bias)
Identifiers	Ticker changes / reuse handled with effective dates	PASS (no ticker changes among the 100 symbols in 2006–2023; tickers checked against listing dates)

品質報告　OHLC 不變式違反、非正價格、重複 (symbol, date) 皆為 0；成交量為 0 的列有 158 列（0.038%，以 VLUE、INDA 為主），處理方式是**標記並排除**（價格設為 NaN，不能進入特徵、標籤或成交），不做任何默默往前補值。相對於 NYSE 交易日曆，各檔上市後內部缺漏交易日為 0。樣本內沒有任何一檔下市（存活者偏誤，見 PIT 表的 FAIL）。每月可交易檔數中位數 87（四分位 74–93），2006 年因歷史長度不足為 0，2015 年後穩定在 85 以上（圖 3.2）。v1 不使用 tick 資料；合成資料（3 檔、60 日）只用於回測引擎的單元驗證，不進入任何結果或總表。代號檢查涵蓋 2006–2023；2024–2025 為維持 holdout 封存而未在開發期檢查。



圖 3.2　Q：策略每個月實際能交易幾檔？灰：有價格；藍：符合資格（歷史 ≥ 273 日且 $ADV ≥ 1,000 萬）。

What could break this　(1) 存活者偏誤：100 檔名單是 2025 年選的，期間關掉的 ETF（多半是失敗的商品或主題型基金）不在樣本中。這主要高估等權基準；對動能多頭部位的影響方向較小（輸家本來就不太會被選中），但仍是向上偏誤。(2) Yahoo 的調整後價格會隨未來配息回溯修改，比率型特徵幾乎不變，但實測重新下載後約 10^{-6} 的差異仍足以改變 Optuna 選出的 LightGBM 超參數與部署模型（第 5 節），但重新下載時調整因子會變，README 已註明。(3) 半價差是依經驗分級，不是實際報價。

4. 標籤、特徵與篩選（Ch. 7–10）

item	value
label	fwd_open_ret_21d
type	fixed-horizon continuous return
execution anchor	fill at open t+1, exit at open t+22
horizon	21 sessions
mean |close-close − open-open| per obs (bp)	85
IC(mom_252_21) close-to-close label	0.0582
IC(mom_252_21) next-open label	0.0569
nominal obs (dev)	352,620
effective obs ~ nominal / horizon	16,791
effective IC days (Bartlett, discovery)	86

標籤　`fwd_open_ret_21d = open[t+22] / open[t+1] − 1`，固定期間連續報酬，錨定「t+1 開盤成交、下次再平衡開盤出場」的回測規則。同一筆觀測下，收盤對收盤與開盤對開盤標籤的平均絕對差是 **85bp**，所以兩者不能混用。訓練目標為逐日橫斷面去均值後的報酬，並以訓練 fold 估計的 1% / 99% 分位做 winsorize。重疊造成名目觀測 352,620 筆，有效樣本約 16,791（÷ 21）；discovery 期 IC 序列的 Bartlett 有效天數只有 **86 天**，所以所有 IC 信賴區間都用 Newey-West（lag 21）。

特徵表（Table 8.1 格式，每個候選一列）　22 個候選：17 個訊號（每個都有可命名的機制與預期方向）與 5 個狀態變數；回看期 ≤ 252 日，每日計算、月頻使用。

feature	role	driver hypothesis	lookback	representation	known failure mode	sign
mom_252_21	signal	Persistence: under-reaction / slow-moving capital (12-1 momentum)	252	return, XS rank	momentum crashes after volatility spikes	+
mom_126_21	signal	Persistence at 6-1 months	126	return, XS rank	regime concentration in one asset class	+
mom_63	signal	Persistence at 3 months (faster trend)	63	return, XS rank	whipsaw in range-bound markets	+
volscaled_mom_252_21	signal	Persistence per unit risk (TS-momentum scaling)	252	return / vol, XS rank	low-vol bond ETFs dominate the ranking	+
sharpe_126	signal	Trend earned with less dispersion repeats	126	mean/std of log returns, XS rank	unbounded when vol -> 0	+
dist_52w_high	signal	Anchoring on the 52-week high delays reaction to news	252	close / 252d max − 1, XS rank	piles up at 0 in sustained bull runs	+
sma_ratio_200	signal	Trend-following: price above its 200d average	200	close / SMA200 − 1, XS rank	lags turning points by months	+
trend_consistency_63	signal	Frog-in-the-pan: gradual information diffuses slowly	63	share of up sessions, XS rank	noisy for low-vol funds	+
mom_accel	signal	Trend acceleration: recent leg vs older leg	126	mom_63 − (mom_126_21 − mom_63), XS rank	flags reversals as acceleration	+
rev_21	signal	Short-term reversal: liquidity provision to 1-month flow pressure	21	return, XS rank	ETF reversal weaker than single stocks	−
rev_5	signal	Weekly reversal: liquidity provision	5	return, XS rank	dominated by noise at monthly horizon	−

feature	role	driver hypothesis	lookback	representation	known failure mode	sign
vol_63	signal	Low-risk anomaly: leverage-constrained investors overpay for risk	63	annualised std, XS rank	mixes asset classes with structurally different vol	−
beta_spy_126	signal	Betting-against-beta: funding constraints	126	OLS beta to SPY, XS rank	beta unstable across regimes	−
max_ret_21	signal	Lottery demand: investors overpay for extreme upside	21	max daily return, XS rank	driven by single events	−
skew_63	signal	Skewness preference: positively skewed assets overpriced	63	sample skewness, XS rank	estimation noise in 63 obs	−
amihud_63	signal	Illiquidity premium: compensation for price impact	63	mean |r| / $volume, XS rank	ETF liquidity != underlying liquidity	+
volume_trend_21_126	signal	Attention: rising participation confirms the move	126	log(ADV21/ADV126), XS rank	index events and rebalancing days	+
asset_rvol_pct	state	Own volatility vs own history: stress state of the asset	252	percentile of vol_21 in own 252d	single shock dominates	(state)
mkt_rvol_pct	state	Market risk environment (SPY 21d vol vs expanding history)	252	expanding percentile	level shifts in vol regime	(state)
mkt_trend	state	Market trend state (SPY vs SMA200)	200	ratio	late at turning points	(state)
corr_spy_tlt_63	state	Hedge regime: stock-bond correlation	63	level	nonsynchronous trading, one pair stands for all	(state)
xs_disp_21	state	Opportunity set: cross-sectional dispersion of 1-month returns	21	XS std	dominated by commodity outliers	(state)

所有訊號在每個決策日對**當日符合資格**的標的做橫斷面百分位排名。相關性分群（$|\rho| \geq 0.8$，依特徵表順序挑代表，**不看 IC**）刪去 2 個重複：`volscaled_mom_252_21`（＝`mom_252_21`）、`max_ret_21`（＝`vol_63`）。

關卡 1a：截斷測試　隨機抽 6 個日期，把資料截在 t 重新計算所有特徵，在 t 的值與全樣本計算**完全相同**，所以沒有未來資訊。之後的獨立稽核又用 12 個月底日期，對完整 panel（含排名與市場層級狀態變數）重做一次，同樣全部通過。

五道關卡篩選（discovery 2008-01 ～ 2014-11，結果 0 PROCEED / 9 REVISE / 8 STOP）

關卡 1–2、5：關聯與多重檢定

feature	sign	IC	lo	hi	ICIR	same-sign yrs	IC 5d	IC 21d	IC 63d	p (NW)	BH	effect d
mom_252_21	+	0.057	−0.011	0.125	0.144	0.714	0.044	0.057	0.021	0.102	—	0.484
mom_126_21	+	0.026	−0.037	0.089	0.07	0.714	0.031	0.026	−0.02	0.418	—	0.221
mom_63	+	0.059	0.005	0.113	0.172	0.857	0.029	0.059	0.039	0.033	—	0.502
volscaled_mom_252_21	+	0.047	−0.011	0.105	0.142	0.714	0.03	0.047	0.029	0.113	—	0.401
sharpe_126	+	0.021	−0.034	0.076	0.065	0.714	0.018	0.021	−0.003	0.457	—	0.178
dist_52w_high	+	0.012	−0.05	0.074	0.033	0.429	0.009	0.012	−0	0.706	—	0.102
sma_ratio_200	+	0.043	−0.017	0.103	0.119	0.714	0.024	0.043	0.021	0.16	—	0.368
trend_consistency_63	+	0.055	0.012	0.097	0.211	0.857	0.032	0.055	0.04	0.011	—	0.466
mom_accel	+	0.032	−0.025	0.089	0.092	0.857	0.001	0.032	0.039	0.27	—	0.272
rev_21	−	0.023	−0.025	0.071	0.07	0.286	0.007	0.023	0.039	0.344	—	0.198
rev_5	−	0	−0.032	0.032	0.001	0.429	−0.006	0	0.012	0.99	—	0.002
vol_63	−	0.05	−0.02	0.12	0.122	0.286	0.028	0.05	0.072	0.159	—	0.428
beta_spy_126	−	0.102	0.023	0.181	0.22	0.286	0.052	0.102	0.15	0.011	—	0.868
max_ret_21	−	0.056	−0.008	0.121	0.147	0.286	0.034	0.056	0.069	0.086	—	0.48
skew_63	−	−0.024	−0.063	0.015	−0.104	0.571	−0.018	−0.024	−0.028	0.224	—	−0.205
amihud_63	+	0.026	0.005	0.048	0.208	0.857	0.015	0.026	0.044	0.015	—	0.225
volume_trend_21_126	+	−0.001	−0.034	0.031	−0.007	0.429	0.004	−0.001	−0.038	0.936	—	−0.011

關卡 1、3–4：安慰劑、形狀與可行性，以及決策

feature	placebo IC (lag 21)	quintile mono.	Q5−Q1 bp/mo	top-quintile turnover/mo	cost bp/mo	decision	reason
mom_252_21	0.045	1	42	0.231	4	REVISE	slow state proxy (placebo survives); CI includes 0 / not BH-significant
mom_126_21	0.001	0.7	42	0.34	6	REVISE	non-monotone quintiles; CI includes 0 / not BH-significant
mom_63	0.034	0.8	78	0.434	8	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
volscaled_mom_252_21	0.036	0.4	51	0.222	4	STOP	duplicate of mom_252_21 (|rho|>=0.8)
sharpe_126	0.008	0.7	28	0.312	6	REVISE	non-monotone quintiles; CI includes 0 / not BH-significant
dist_52w_high	0.011	0.9	39	0.416	8	STOP	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
sma_ratio_200	0.04	0.9	55	0.308	6	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant

feature	placebo IC (lag 21)	quintile mono.	Q5−Q1 bp/mo	top-quintile turnover/mo	cost bp/mo	decision	reason
trend_consistency_63	0.043	0.9	65	0.433	8	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
mom_accel	0.039	0.9	61	0.563	10	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
rev_21	0.018	−0.6	−51	0.743	14	STOP	sign opposite to mechanism; no stable support
rev_5	0.03	1	83	0.746	14	STOP	sign opposite to mechanism; no stable support
vol_63	0.052	−0.3	−12	0.084	2	STOP	sign opposite to mechanism; no stable support
beta_spy_126	0.101	−1	−81	0.051	1	STOP	sign opposite to mechanism; no stable support
max_ret_21	0.05	−0.6	−20	0.215	4	STOP	duplicate of vol_63 (|rho|>=0.8)
skew_63	−0.024	0.7	28	0.465	9	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
amihud_63	0.026	0.5	37	0.121	2	REVISE	slow state proxy (placebo survives); non-monotone quintiles; CI includes 0 / not BH-significant
volume_trend_21_126	−0.03	0.3	18	0.553	10	STOP	sign opposite to mechanism; no stable support

讀法：IC 為日 Spearman IC 平均與 NW 95% CI，ICIR 為日 IC 平均 / 標準差；same-sign yrs 為 7 個年度區塊中方向符合機制的比例；IC 5d / 21d / 63d 為三個期間的 IC 衰減；effect d 為以平均橫斷面樣本數換算的效果量（與 BH 一起報告）；placebo 為特徵延後 21 日的 IC（若仍存活代表是「慢速狀態代理」而非即時資訊）；單調性為五分位平均標籤的 Spearman（≥ 0.9 視為單調，0.9 的列實際值略低於 0.9）；價差與成本皆為每月 bp、以預期方向計算（成本 = 前五分位換手 × 2 倍來回成本）。**Benjamini–Hochberg（α = 0.05，17 個訊號）沒有任何特徵顯著**，這是沒有 PROCEED 的主因。

值得記下的 STOP `beta_spy_126` 的 IC = 0.102 [0.023, 0.181] 是全表最大、NW 區間不含 0（名目 p = 0.011，BH 校正後不顯著），但方向與「betting-against-beta」機制**相反**；看了資料才把方向反過來，就等於一個新假說，所以在 v1 一律 STOP，並列為下一版的候選。短期反轉（`rev_21`、`rev_5`）在 ETF 上也不成立。

狀態變數與機制檢驗（證偽條件 ④，discovery） 以擴張式、時間點正確的三分位門檻，計算 12–1 動能 IC 在 SPY 波動三分位下的表現：低 0.091、中 −0.030、高 0.084。高波動並沒有比較差，**在 discovery 期間，機制的「波動開關」部分未獲支持**（但高波動只有 151 天，CI 很寬）。在驗證期這個結果反轉了（第 5、6 節）。

前三名特徵的機制合理性（DAG + 四項檢查） 圖 4.1 為 `trend_consistency_63`、`amihud_63`、`mom_63` 的 DAG：控制市場 beta / 資產類別與波動狀態（干擾因子）；資金流是中介變數（不控制）；基金規模與存活是碰撞變數（絕不控制，否則會造成偽相關）。

feature	ic	placebo_lag5	placebo_lag21	ic_after_beta_group_control	ic_calm	ic_mid	ic_stressed	event_time
trend_consistency_63	0.055	0.054	0.043	0.025	0.053	0.069	0.044	N/A (not event-based)
amihud_63	0.026	0.026	0.026	0.03	0.012	0.07	−0.005	N/A (not event-based)
mom_63	0.059	0.058	0.034	0.009	0.073	0.049	0.007	N/A (not event-based)

`mom_63` 在控制 beta 與資產類別後，IC 從 0.059 掉到 0.009，代表它多半是在挑「哪一類資產」而不是挑個別 ETF；`amihud_63` 在控制後仍存活，但在高波動時消失。三者都不是事件型特徵，事件時間對齊不適用。

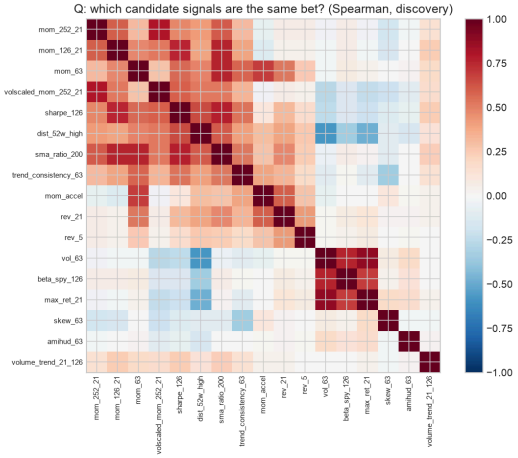


圖 4.0　Q：哪些候選訊號其實是同一個賭注？discovery 期 Spearman 相關矩陣（|ρ| ≥ 0.8 者刪除）。

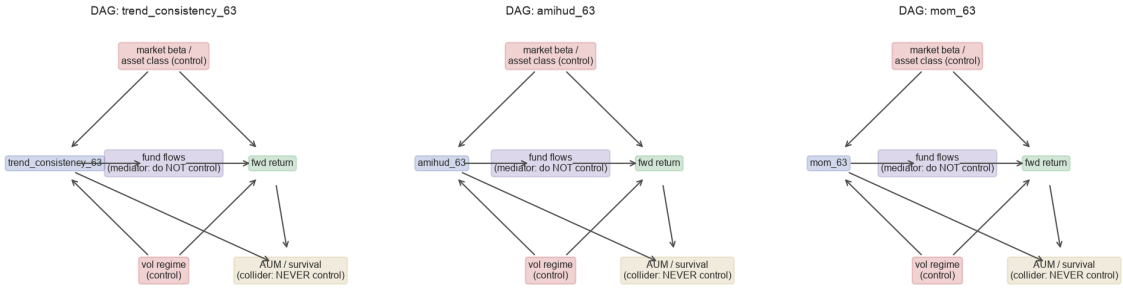


圖 4.1　Q：前三名特徵各自要控制什麼、不能控制什麼？紅：干擾因子（控制）；紫：中介變數（不控制）；黃：碰撞變數（絕不控制）。

> **What could break this**　Discovery 只有 7 年、86 個有效 IC 天，五道關卡的檢定力很低，REVISE 的特徵進入模型其實是「寬鬆放行」；如果標準提高到只收 PROCEED，模型就沒有任何訊號特徵可用。安慰劑測試顯示，大部分動能類特徵都是慢速狀態代理，這在月頻策略中可以接受，但也表示它們和 beta / 資產類別輪動高度重疊。

5. 模型、驗證、解讀與不確定性（Ch. 11–15）

基準階梯　① 規則：依 `mom_252_21` 排名（不擬合）；② Ridge：9 個 REVISE 訊號＋各自與市場波動狀態的交互作用，標準化只在訓練 fold 上 fit；α 在 10^{-4}～10^{5}（10 個值、9 個數量級）中依 2014 年 IC 選出 **10^{5}**（網格邊界；與課本圖 11.1「ICIR 高峰出現在很大的 α」一致）；③ LightGBM：MAE（L1）損失、淺樹，Optuna TPE 50 次試驗，在 2014 年提早停止後凍結（num_leaves 12、max_depth 3、學習率 0.0116、min_child_samples 562、295 輪）；⑤ 集成：前三者逐日 z 分數平均。訓練列每 5 個交易日取 1 天，以降低標籤重疊。

驗證期（2015–2023，9 fold）的共同尺度：日 Spearman IC 與 NW 95% CI

	IC	CI_lo	CI_hi	p	ICIR(daily)	share_pos_folds	n_eff_days	days
rule	0.019	−0.029	0.066	0.439	0.058	0.667	128	2,242
ridge	0.045	0.005	0.085	0.026	0.159	0.778	142	2,242
lgbm	0.078	0.042	0.113	0	0.3	0.778	147	2,242
ensemble	0.06	0.02	0.101	0.004	0.21	0.667	137	2,242

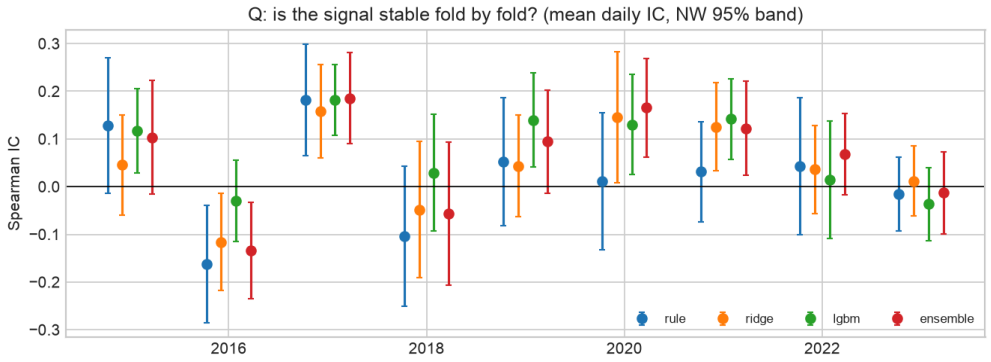


圖 5.1　Q：訊號每個 fold 都穩定嗎？各 fold 平均日 IC 與 NW 95% 區間；2016、2018、2023 規則為負；LightGBM 在 2016 損失較小（−0.030 vs −0.163）、2018 轉正（+0.030），但 2023 比規則更差（−0.037 vs −0.016）。

集成的離散度　各 fold 日 IC 的標準差：規則 0.106、Ridge 0.090、LightGBM 0.082、集成 0.106。集成沒有降低離散度（反而高於 LightGBM），所以不採用集成的理由不只是成對檢定，也包括它沒有帶來穩定性。

成對比較（日 IC 差，NW 95% CI）與部署決策

comparison	dIC	lo	hi	p
ridge − rule	0.026	−0.02	0.072	0.265
lgbm − ridge	0.033	0.003	0.063	0.033
lgbm − rule	0.059	0.011	0.107	0.016
ensemble − rule	0.042	0.008	0.075	0.014
ensemble − ridge	0.015	−0.005	0.036	0.146
ensemble − lgbm	−0.017	−0.042	0.007	0.171

依事先登錄的規則（部署最複雜、且相對「最佳較簡單階」成對差 CI 下界 > 0 的那一階）：集成 vs LightGBM 下界 −0.042，不成立；**LightGBM vs Ridge 下界 +0.0026 → 部署 LightGBM**。這個邊際很薄，而且必須說明：稽核前的

程式誤把比較對象寫成「最後一個通過的階」（規則），稽核後才改成合約文字的「最佳較簡單階」。同時修正了調參窗口的 purge，LightGBM 重新調參後，下界才從 −0.0015 變成 +0.0026（附錄 A3）。

SHAP（描述性，非因果） 前幾大是 `mkt_rvol_pct`、`mom_252_21`、`sharpe_126`。方向檢查：`mom_252_21`、`mom_63`、`sma_ratio_200` 的 SHAP 與特徵值正相關（符合延續機制，9 個 fold 中分別有 9 / 9 / 8 個方向一致）。**出乎意料的歸因**：`sharpe_126` 的 SHAP 與特徵值**負**相關（−0.61，9 個 fold 全部一致），和「風險調整後動能」的機制相反。我的解讀是：在已經有原始動能的情況下，高 Sharpe 往往代表低波動的債券型 ETF，模型其實是在用它降低債券權重，換句話說是資產類別效果，而不是動能本身。`mkt_rvol_pct` 是每天所有標的都相同的值，它的 SHAP 大多只是整天的水準移動，對橫斷面排名沒有影響，只有透過交互作用才有用。各 fold 重要性排名的平均 Spearman 為 0.53，屬於中度穩定。**大小合理性**：最大平均 |SHAP| 約 0.0010（相當於 21 日去均值報酬約 10bp），對照篩選表中每月 40–80bp 的五分位價差，對月頻橫斷面訊號而言是合理的量級。

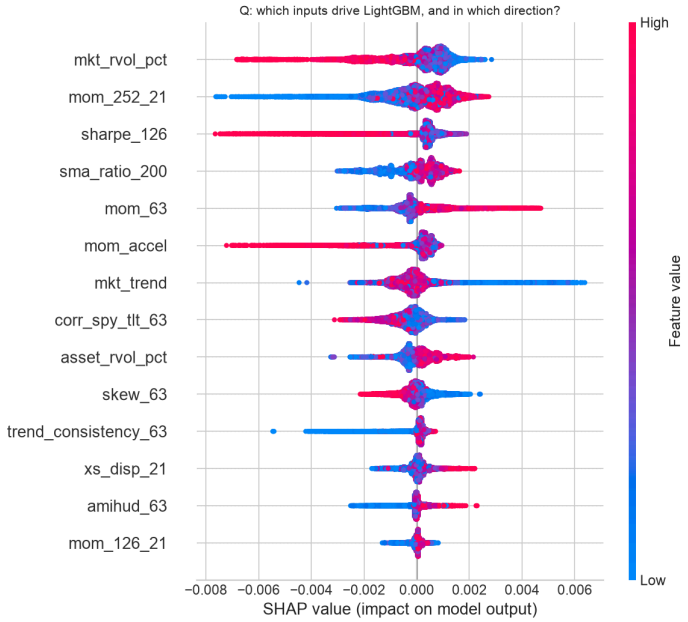


圖 5.2　Q：LightGBM 依賴哪些輸入、方向為何？9 個驗證 fold 合併的 SHAP beeswarm。

Conformal 預測區間 以每個 fold 訓練窗的最後 252 日為校準集（與核心訓練集之間再 purge 22 日）。80% 區間的實際覆蓋率在 2015（0.75）、2018（0.72）、2020（0.63）、2022（0.71）**低於 80%**，90% 區間在 2020 年只有 0.76。這四年都是波動突增的年份，和「校準過時」的預期一致。Ridge 與 LightGBM 的覆蓋率幾乎相同。

fold	coverage 80%	coverage 90%	flag < 80%
2015	0.753	0.863	FLAG
2016	0.804	0.893	
2017	0.881	0.953	
2018	0.718	0.855	FLAG
2019	0.811	0.915	
2020	0.634	0.758	FLAG
2021	0.876	0.949	
2022	0.706	0.822	FLAG
2023	0.893	0.952	

What could break this (1) LightGBM 勝過 Ridge 的證據只有一個邊際顯著的成對差，而且做了 50 次 Optuna 試驗。(2) 超參數只用 2014 年選出。(3) SHAP 顯示模型很大一部分是在做「資產類別擇時」，這在 holdout 可能表現為 portfolio-translation drift（第 7 節證實）。(4) **對資料雜訊不穩健**：最終審查以重新下載的資料（實際成交價、成交量完全相同，只有調整因子差約 2×10^{-6}）重跑 01–05，Optuna 選出不同的超參數，LightGBM 驗證 IC 由 0.078 降為 0.065，LightGBM − Ridge 的下界變成 −0.007，依同一部署規則會改選 12-1 規則。換句話說，「部署 LightGBM」這個決定取決於浮點層級的雜訊；本報告仍依凍結的快照與規格報告，但這是 LightGBM 優勢最重要的反證。(5) 驗證與 holdout 是否一致的診斷留到第 7 節。

6. 回測協定、基準、投組、成本與風險（Ch. 16–19）

協定（事前固定，Table 16.2 的六項）

Component	Specification
Signal timing	t 收盤產生分數 → t+1 開盤成交（延遲 1 交易日）；同根 K 棒成交視為 lookahead

Component	Specification
Rebalance & holding	月頻；持有至下次再平衡開盤（≈ 21 交易日 = 標籤期間）
Position sizing	前 10 名等權、單檔上限 10%（配置比較：前 20 名、上限 10%）
Fill assumptions	以開盤價全額成交（ADV ≥ $10M，部位遠小於成交量，不模擬部分成交）；該日無有效價格則不交易、保留原權重
Constraints	只做多、滿倉、槓桿 ≤ 1，於模擬迴圈內每次再平衡檢查；缺價保留舊權重時其他標的同比例縮減
Costs	每股 $0.0035 + 分級半價差，以未調整開盤價換算；掃描 0–8 倍；壓力測試價差 × 3

引擎：自寫的逐日事件迴圈（權重每日漂移）。不用純向量化，是因為波動目標覆蓋與無法成交規則會影響下一步動作。引擎另以合成資料（3 檔、60 天、已知價格）做單元測試，確認報酬與成本計算和手算一致。

驗證期績效（2015–01 ～ 2023–12，相同協定，扣成本）

strategy	gross_sharpe	net_sharpe	net_sr_lo	net_sr_hi	net_cagr	vol	max_dd	turnover_2way_ann
deployed_lgbm	0.678	0.634	−0.02	1.289	0.097	0.169	−0.299	16.674
rule_mom_252_21	0.478	0.461	−0.194	1.115	0.071	0.189	−0.295	7.168
ridge	0.515	0.48	−0.175	1.134	0.076	0.192	−0.408	12.367
ensemble	0.644	0.609	−0.046	1.263	0.098	0.18	−0.328	12.75
EW_all_eligible	0.547	0.544	−0.11	1.199	0.068	0.138	−0.301	0.561
60/40 SPY/AGG	0.764	0.764	0.109	1.418	0.078	0.106	−0.221	0.313
SPY	0.733	0.733	0.079	1.387	0.118	0.172	−0.32	0.111

部署模型勝過非 ML 規則（0.46）與全體等權（0.54），但**輸給 60/40（0.76）與 SPY（0.73）**。課本的 ETF 基準（Sharpe 0.65 vs 60/40 的 0.80）也有同樣不討好的結果。

成本敏感度　假設成本中位數每腿 3.4bp。損益兩平成本 c* = 年化毛報酬 ÷ 年化雙邊換手：部署模型 **69bp/腿**（相對等權基準 24bp），規則 126bp/腿，屬於「舒適區」。成本放大到 4 倍時淨 Sharpe 仍有 0.50，8 倍時 0.33。換手偏高：年化雙邊 16.7 倍，平均持有約 1.4 個月；規則只有 7.2 倍。

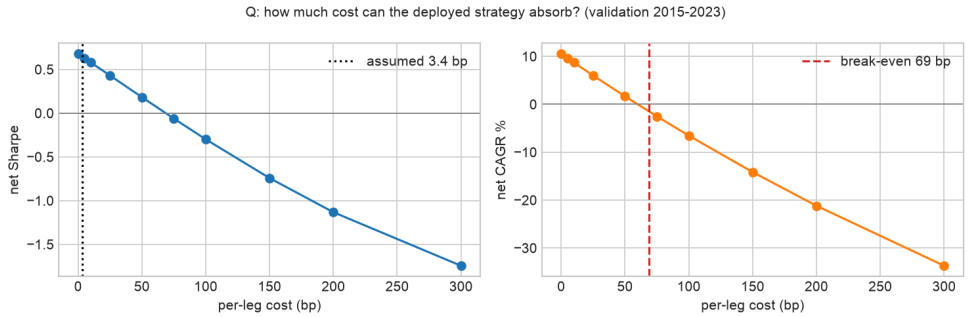


圖 6.1　Q：部署策略能承受多少成本？左：淨 Sharpe 對每腿成本（虛線＝假設成本）；右：淨 CAGR 與損益兩平。

投組配置（相同訊號、相同 63 日共變異窗）　前 10 名搭配 10% 上限時，任何滿倉配置都會退化成等權，因此改用前 20 名候選集做對照比較：

allocator	net_sharpe	max_dd	turnover_2way_ann	HHI	effective_bets
equal_weight (top-20)	0.577	−0.342	13.038	0.05	20
inverse_vol (top-20)	0.612	−0.333	13.699	0.055	18.333
hrp (top-20)	0.599	−0.343	15.459	0.064	15.681
best–worst spread	0.035				

最佳與最差的差距只有 0.035 Sharpe，比不同訊號之間的差距小一個數量級，與課本中位數 0.49「配置救不了弱訊號」的結論一致；這裡沒有使用 mean–variance，所以不需要 Ledoit–Wolf。

風險控制矩陣（Table 19.2 精簡版）

風險	代理指標	控制	頻率
市場	對 SPY 的滾動 252 日 beta（平均 0.90，HAC 區間 0.81–0.99；最低 0.75 於 2019–11，最高 1.15 於 2018–01）	波動目標覆蓋；停損階梯	每日監看、每月行動
因子 / 集中	資產類別權重、HHI、有效標的數	單檔 ≤ 10%；前 10 名	每次再平衡
槓桿	總曝險	≤ 1.0，在模擬內檢查	每次再平衡
流動性	63 日美元成交量中位數	資格門檻 ≥ $10M；成交日缺價不交易	每月
模型	滾動 63 日 IC、PSI、conformal 覆蓋率	重訓 / 暫停規則（第 8 節）	每月
作業	資料快照雜湊、holdout 存取紀錄、規格雜湊	程式閘門與 git	每次執行

	VaR95	CVaR95	days
all	0.016	0.025	2,263
high vol	0.02	0.031	1,051
low vol	0.012	0.019	1,212

尾端與路徑風險　每日歷史 VaR95 為 1.62%，CVaR95 為 2.55%；高波動狀態下分別是 2.03% 與 3.08%，低波動狀態下 1.20% 與 1.90%。最大回撤 −29.9%：2020-02-14 到 2020-03-23 共 26 個交易日，114 個交易日後（2020-09-02）才回到前高。

壓力測試（價差 × 3，只放大價差、不放大手續費）

episode	strategy	return	max_dd
covid_2020	deployed (3x spreads)	-0.153	-0.299
covid_2020	deployed + overlay (3x spreads)	-0.148	-0.204
covid_2020	rule (3x spreads)	-0.098	-0.295
covid_2020	60/40	-0.061	-0.214
covid_2020	SPY	-0.128	-0.321
rate_shock_2022	deployed (3x spreads)	-0.099	-0.186
rate_shock_2022	deployed + overlay (3x spreads)	-0.057	-0.102
rate_shock_2022	rule (3x spreads)	0.097	-0.197
rate_shock_2022	60/40	-0.165	-0.219
rate_shock_2022	SPY	-0.178	-0.263

COVID 期間部署模型（−15.3%）比規則（−9.8%）和 60/40（−6.1%）更差。2022 年升息衝擊時是 −9.9%，比 60/40 的 −16.5% 好，但規則反而 **+9.7%**（12-1 動能及早轉進能源與美元）。

波動目標覆蓋（10%，只用 t−1 資訊；有 / 無覆蓋並列）　加上覆蓋後淨 Sharpe 由 0.63 **降到** 0.54，最大回撤由 −29.9% 縮小到 −20.5%，平均曝險 0.73。覆蓋只是降低風險，並沒有創造報酬；它也不是讓策略轉正的原因（「overlays refine, never redeem」）。

停損階梯（Table 19.7 格式）

回撤門檻	行動	負責人
5%	watch：檢查 parity 與資料	研究者
10%	halve gross：曝險減半	研究者
15%	halt new trades：停止新交易	風險審核者 / 指導老師核可
20%	unwind：全部平倉	風險審核者 / 指導老師核可

驗證期依「回撤事件」計算各觸發 8 / 5 / 5 / 1 次（圖 7.6），20% 只在 2020 年 3 月觸發。v1 的停損階梯是**事後計數，沒有在模擬中執行**（只有波動目標覆蓋有模擬），所以不能說「加了停損會更好」。

統計推論（驗證期）　淨 Sharpe 0.63，95% CI [−0.02, 1.29]；PSR(SR>0) = 0.97；偏態 −0.82、峰態 12.2。依帳本 N = 93 次試驗計算的 **DSR = 0.28**（零技能下預期最大 Sharpe 0.84）；若只計 8 個策略層級配置，DSR = 0.67。最短紀錄長度依課本公式為 15 年，依 Bailey–López de Prado 公式為 7.0 年。

> **What could break this**　beta 0.90 表示策略大部分報酬來自美股多頭，2015–2025 恰好是美股強勢期；換到股市橫盤的十年，策略與 60/40 的差距可能更大。換手 16.7 倍在成本上沒有問題，但代表模型的排名不穩定。壓力測試只有兩段，而且兩段都在驗證期內，參數也是看過驗證期之後才「固定」的。

7. 結果、診斷與下一步（Ch. 20）

Holdout 只執行一次：2026-11-08 23:39（`results/holdout_access.log`：touch #1，spec `7e75995d042147ae`）。執行前用開發期資料（2022–2023 代替 holdout）做過完整的試跑，確認程式不會中途當掉、需要第二次觸碰。

Stage	Metric	Validation 2015–2023	Holdout 2024–2025	Benchmark
Signal	Daily IC [NW 95% CI]	0.078 [0.042, 0.113]	0.064 [−0.014, 0.142]	–
Signal	ICIR (daily) / share of positive folds	0.300 / 0.78	0.249 / 1.00	–
Portfolio	Gross Sharpe [95% CI]	0.68 [0.02, 1.33]	1.11 [−0.29, 2.50]	val: EW 0.55 · 60/40 0.76 · SPY 0.73; holdout: EW 1.31 · 60/40 1.39 · SPY 1.27
Portfolio	Max drawdown / 2-way turnover p.a.	−29.9% / 16.7x	−19.9% / 14.3x	val: EW −30.1%/0.56x · 60/40 −22.1%/0.31x · SPY −32.0%/0.11x; holdout: EW −13.1%/0.96x · 60/40 −11.7%/0.64x · SPY −19.8%/0.50x
Costs	Net Sharpe [95% CI] at assumed cost	0.63 [−0.02, 1.29]	1.08 [−0.31, 2.47]	val: EW 0.54 · 60/40 0.76 · SPY 0.73; holdout: EW 1.31 · 60/40 1.39 · SPY 1.27
Costs	Break-even cost (bp per leg)	69	128	–
Risk overlay	Net Sharpe / MDD with 10% vol target	0.54 / −20.5%	1.09 / −13.1%	–
Inference	Skew / kurtosis of daily net returns	−0.82 / 12.2	−0.80 / 13.0	–
Inference	Deflated Sharpe (trials = N) / min. track record	0.28 (N=93) / 15 y	0.17 (N=93) / 5 y	–

結果型態（Ch. 20 五型） never resolved：驗證期與 holdout 的淨 Sharpe 區間都跨 0（[−0.02, 1.29] 與 [−0.31, 2.47]）；IC 方向維持（驗證期 CI 不含 0，holdout 含 0）。預先登錄的確認檢定**通過**：holdout 平均 IC 0.064 > 0、淨 Sharpe 1.08 > 0。但 IC 的 95% CI [−0.014, 0.142] 與 Sharpe 的 CI [−0.31, 2.47] 都含 0；兩年日資料的 Sharpe 標準誤約 ±0.7，1.08 和 0 在統計上幾乎無法區分。

Holdout 各階的訊號與投組結果（同一凍結規格）

	mean	lo	hi	p	icir_daily	share_pos_folds	T
rule	0.049	−0.035	0.133	0.252	0.182	1	480
ridge	0.076	−0.007	0.159	0.073	0.282	1	480
lgbm	0.064	−0.014	0.142	0.109	0.249	1	480
ensemble	0.073	−0.015	0.162	0.105	0.257	1	480

strategy	gross_sharpe	net_sharpe	net_sr_lo	net_sr_hi	net_cagr	vol	max_dd	turnover_2way_ann
deployed_lgbm	1.105	1.077	−0.315	2.468	0.179	0.166	−0.199	14.274
rule_mom_252_21	1.359	1.345	−0.048	2.738	0.25	0.178	−0.17	5.938
ridge	1.395	1.357	−0.036	2.749	0.246	0.173	−0.187	15.408
ensemble	1.137	1.116	−0.275	2.508	0.21	0.187	−0.213	11.901
deployed + vol target	1.124	1.094	−0.298	2.486	0.136	0.123	−0.131	11.233
EW_all_eligible	1.314	1.31	−0.082	2.703	0.16	0.119	−0.131	0.961
60/40 SPY/AGG	1.388	1.388	−0.005	2.78	0.15	0.105	−0.117	0.641
SPY	1.271	1.271	−0.121	2.663	0.223	0.169	−0.198	0.503

各階段在 holdout 的比較　訊號端，LightGBM 的 IC（0.064）仍高於規則（0.049），Ridge 最高（0.076）。投組端卻**相反**：淨 Sharpe 規則 1.35、Ridge 1.36、等權 1.31、60/40 1.39、SPY 1.27，部署模型 1.08 墊底。毛 Sharpe 1.11 對淨 1.08，成本並不是原因。

診斷　(1) **價值在哪一關流失**：不是訊號關（IC 方向維持）、不是成本關（兩平 128bp），而是 **portfolio gate**：IC 穩定、Sharpe 下降，這是 Ch. 20 定義的 **portfolio-translation drift**。2024–2025 是全面多頭（等權 Sharpe 1.31），在 beta 主導的市場中，換手 14 倍、前 10 名集中的排名轉換，把小幅的 IC 優勢吃掉了。(2) **市場狀態**：holdout 只有 42 天屬於「高波動 / 下跌趨勢」，沒有「低波動 / 下跌」，等於沒有真正的空頭可以檢驗波動開關。(3) **機制**：證偽條件 ④ 在驗證期**沒有**被觸發：動能 IC 平靜 0.095 [0.022, 0.169]、中 0.032、壓力 −0.075 [−0.160, 0.011]，支持波動開關；但在 discovery 期被否定。兩段資料互相矛盾，所以只能說「未定」。(4) **限制因素**：construction robustness（排名→權重的轉換不夠穩健）。(5) **ML 優勢本身不穩健**：重新下載資料重跑開發期會改選 12-1 規則（第 5 節）；holdout 中 Ridge 的 IC（0.076）也高於 LightGBM。驗證期各狀態的最差回撤：高波動 / 下跌 −20.4%、高波動 / 上漲 −19.0%、低波動 / 上漲 −16.9%。

唯一的下一步　把部署模型的分數先做 3 個月指數平滑再取前 10 名，把換手壓到與規則同級（≈ 6–7 倍/年），然後用同一個 walk-forward 協定重測 portfolio gate。 這屬於映射規則的改變，是 setup v2，需要新的 holdout（例如 2026 年起的前推資料）。不再調模型參數。依課本結論，這個第一輪策略不直接投入資金。

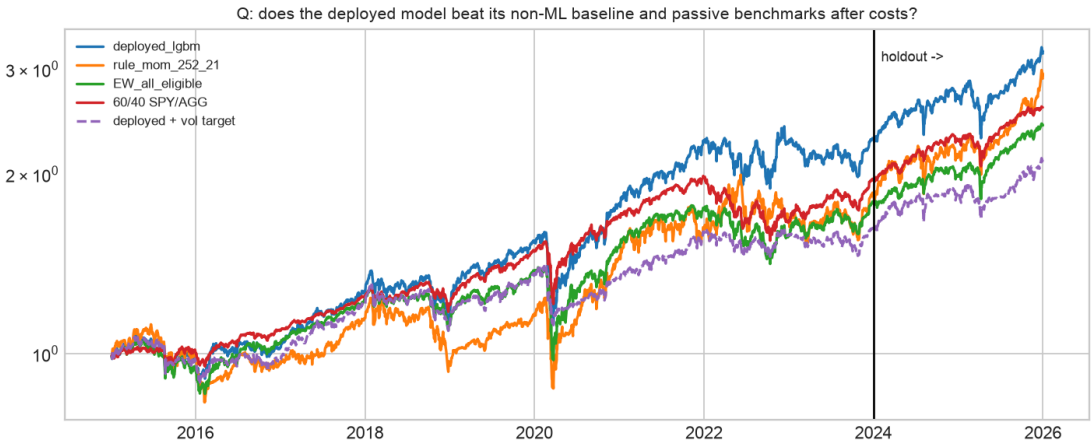


圖 7.1　Q：部署模型在扣成本後是否勝過非 ML 基準與被動指標？黑線為驗證 / holdout 分界。holdout 中規則縮小了差距（holdout 累積 +55.9% vs 部署 +38.7%），但整段累積報酬仍是部署模型領先（+219% vs +190%）。

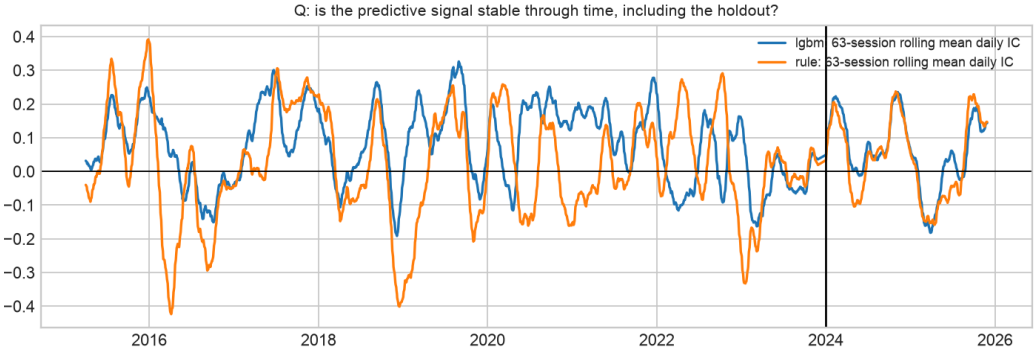


圖 7.2　Q：預測訊號在時間上穩定嗎？63 日滾動平均日 IC；2016、2018、2022、2023 年有較長的負區段（2017、2019、2020 也有短暫負值）；holdout 大致為正，但 2025 年（主要在上半年，關稅衝擊前後）有負值。

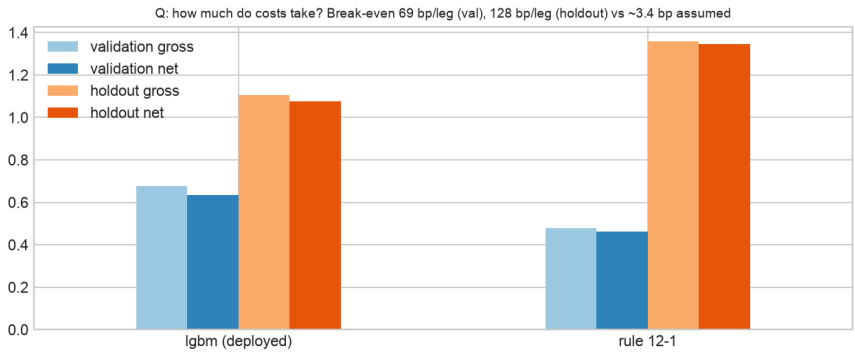


圖 7.3　Q：成本吃掉多少？毛 vs 淨 Sharpe；成本不是瓶頸（兩平 69bp 驗證 / 128bp holdout vs 假設 3.4bp）。

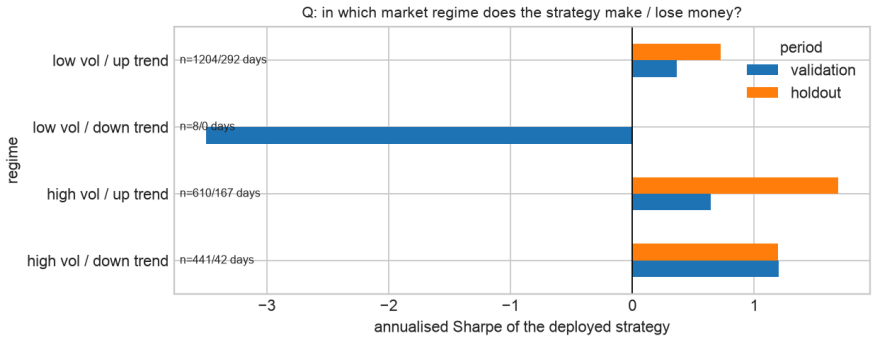


圖 7.4　Q：策略在什麼市場狀態賺 / 賠錢？狀態門檻用 t−2 收盤、擴張式中位數（時間點正確）；「低波動 / 下跌」只有 8 / 0 天，不具解讀價值。

圖 7.5（SHAP beeswarm）即圖 5.2。

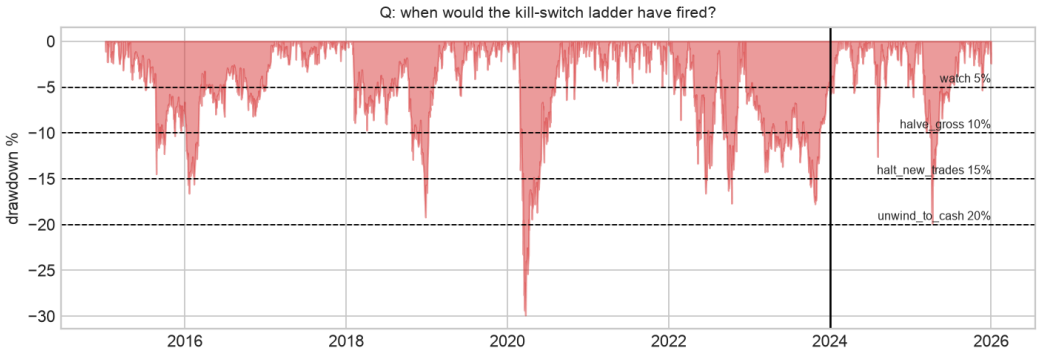


圖 7.6　Q：停損階梯什麼時候會觸發？虛線為 5 / 10 / 15 / 20% 門檻；20% 只在 2020 年 3 月觸發，holdout 最深 −19.9%（2025 年 4 月關稅衝擊）。

> **What could break this**　holdout 只有兩年，又是罕見的全面多頭；「確認檢定通過」很可能只是 beta 的功勞（holdout 中連等權都有 1.31）。DSR 0.17 表示在 93 次試驗下，這個 Sharpe 不足以排除運氣。

8. 監控與部署計畫（Ch. 25–26，設計而非實作）

一致性（parity）　實盤與回測共用同一個 `etfmom` 套件：資料 → 特徵 → 預測 → 訊號 → 委託，每一層存快照並計算雜湊，逐層比對回測與實盤（原始價格、特徵值、預測排名、目標權重、成交價差）。**監控**：每月計算 30 / 60 / 90 日滾動 Sharpe、回撤、命中率、IC，以及實盤 / 回測的實現比率（< 0.5 連續 3 個月就調查）。**漂移**：前 5 大特徵的 PSI（0.10–0.25 觀察，> 0.25 重訓），加上 SHAP 排名檢查（前 5 名有 2 個以上換掉即調查）；conformal 覆蓋率 < 80% 代表校準過時。**生命週期**：每年初例行重訓；60 日 IC < 0 而且 PSI > 0.25 → 暫停；連續 12 個月 IC 的 NW CI 上界 < 0、或回撤 ≥ 20% → 退場；正式投入資金前至少 6 個月影子交易（shadow mode）。**區分三種失效**：技術 bug（parity 某一層出現斷點 → 修程式，不重訓）、統計衰退（IC 與 PSI 同時惡化 → 重訓或退場）、成本膨脹（毛 Sharpe 穩定、淨 Sharpe 下滑或實際價差 > 假設 2 倍 → 降低再平衡頻率）。

> **What could break this**　月頻策略一年只有 12 個決策點，30 日監控指標的雜訊遠大於訊號；觸發門檻需要用影子交易期的資料重新校準，而不是直接沿用回測分布。

附錄 A　研究帳本、執行紀錄、程式庫地圖

A1. 研究帳本摘要（`run_log.csv`，共 196 列 run）

Trial family	試驗數	內容	評估窗
feature_triage	21（+ 去重紀錄 1）	17 訊號五道關卡、4 狀態三分位	discovery 2008–01 ～ 2014–11
ridge_alpha	10	$\alpha = 10^{-4} \ldots 10^{5}$	2014 調參窗
lgbm_optuna	50	TPE、提早停止	2014 調參窗
model_ladder	4（+ 部署決策 1）	rule / ridge / lgbm / ensemble	驗證 2015–2023
strategy_backtest、allocator、risk_overlay	8	4 策略、3 配置、1 覆蓋	驗證 2015–2023
holdout	1	確認檢定（PASS）	2024–2025，唯一一次

試驗次數依 (family, trial) 去重計算，決策與去重紀錄列不計入（N = 93）。帳本 1–103 列是稽核前的第一次執行（含一次只改報表的重跑），104–195 列是稽核修正後的重跑，196 列是 holdout 確認檢定；同一個試驗名稱不重複計數，但兩次的結果都保留在帳本中。

A2. Walk-forward 切分日期（交易日，purge 22）

name	train_start	train_end	valid_start	valid_end
2015	2007-01-01	2014-11-28	2015-01-02	2015-12-31
2016	2007-01-01	2015-11-30	2016-01-04	2016-12-30
2017	2007-01-01	2016-11-29	2017-01-03	2017-12-29
2018	2007-01-01	2017-11-28	2018-01-02	2018-12-31
2019	2007-01-01	2018-11-27	2019-01-02	2019-12-31
2020	2007-01-01	2019-11-27	2020-01-02	2020-12-31
2021	2007-01-01	2020-11-30	2021-01-04	2021-12-31
2022	2007-01-01	2021-11-30	2022-01-03	2022-12-30
2023	2007-01-01	2022-11-29	2023-01-03	2023-12-29

Holdout fold：2024 年模型 train_end 2023-11-28；2025 年模型 train_end 2024-11-27（依同一協定以 2024 年資料重訓，屬於凍結規格的一部分）。`run_log.csv` 的 eval_window 欄只記錄整段區間；各 fold 的切分日期以本表（`results/tables/04_fold_dates.csv`）為準。gate 欄只在有關卡的試驗家族（特徵篩選、部署決策、holdout）填寫。

A3. Holdout 前的洩漏檢查（5 個面向，每個發現再反向驗證）

已確認並修正的問題：(1) discovery 與調參窗的**末端**沒有 purge，2014 年最後 22 日的標籤讀到 2015 年開盤 → 改成窗口截在 2014-11-28；(2) 部署規則的實作與合約文字不一致 → 改用「最佳較簡單階」；(3) 帳本的 git commit 欄位沒有把未追蹤的新檔案算成 dirty。低嚴重度的修正包括：波動覆蓋改成不使用成交當天的開盤價、狀態標籤延遲由 t−1 改為 t−2、壓力測試只放大價差、刪除尾端多出來的零報酬日、缺價時確保總曝險 ≤ 1、試驗數排除紀錄列、新增 Bailey–López de Prado 的 MinTRL。修正後 03–05 全部重跑。修正前後部署模型都是 LightGBM，但成對檢定的結論是在修正後才成立，已在第 5 節揭露。**沒有發現特徵、標籤、purge 或回測引擎有前視偏誤。**

交件前另做一次最終檢查：依評分表逐條對照、把文中數字與結果表逐一核對，並從乾淨的 git clone 依 README 重跑一次。核對出的文字與數字錯誤已修正；重跑發現的資料雜訊敏感度已寫入第 5、7 節。

A4. 程式庫地圖與重現方式

```
setup.yaml                  交易設定 v1（合約）          run_log.csv          研究帳本
src/etfmom/                 data / features / models / backtest / metrics / ledger
scripts/download_data.py    重建資料集                   scripts/run_notebooks.py  執行 01–05（06、07 需明示）
scripts/freeze_spec.py      凍結規格（holdout 閘門需要）  scripts/build_report.py   產生本 PDF
notebooks/01_setup … 07_results（.py 為原始碼，.ipynb 為執行結果）
results/tables, results/figures, results/holdout_access.log
```

時間軸聲明　所有階段都在 2026-11-08 同一個工作階段內完成（commit `73fd93f` → 交件，23:17 起），並非橫跨六週。能證明「協定先於結果」的是 commit 的**順序**：`setup.yaml` 與空帳本（`73fd93f`）先於資料（`e1582a7`），資料先於任何回測（`0f477e4`），凍結規格（`b983dbb`）先於唯一一次 holdout 觸碰（`8cd248b`）；git 歷史未改寫。

重現　(a) 重現 holdout 與總表：`uv sync` → `uv run python scripts/download_data.py` → `HOLDOUT_RERUN=1 uv run python scripts/run_notebooks.py 06 07`（使用已 commit 的凍結規格；以新下載的資料，最終審查實測

holdout 淨 Sharpe 1.10，原值 1.08）。(b) 重跑開發期 01–05：會覆寫 `results/artifacts/*.json`，使凍結規格的雜湊檢查拒絕執行 06（`git checkout results/` 可還原），而且如第 5 節所述，部署模型可能改變；每次重跑也會在帳本新增列。數字差異的其他來源：LightGBM 多執行緒（已設 `deterministic`、seed 42）。